

CROCODILE 框架的轻量化稳定思想、实现与应用

摘要：胸部 X 光多标签疾病分类中，深度学习模型利用统计学习思想，容易捕捉设备、体位等域相关的虚假特征，导致在分布外数据上泛化性能下降。本文基于因果表示学习与结构因果模型，借鉴 CROCODILE 框架中的后门调整思想，设计了一个轻量化可稳定训练的因果查询分类模型。模型采用 ResNet50 提取共享特征，通过轻量特征投影、Transformer 编码器与任务查询机制聚合类别级疾病证据，并引入批内置换与 Dropout 构造干预表示实现后门调整的近似训练。在 CheXpert 五类任务上的实验结果表明，稳定模型在平均 AUC 上达到 0.837，经阈值校准后的平均 F1 为 0.646。在此基础上，本文进一步探讨融合图注意力因果结构学习的完整框架，并通过消融实验分析了训练不稳定的主要来源。本文工作为因果表示学习在医学影像分析中的实际应用提供了可复现的参考案例。

关键词：因果表示学习；胸部 X 光分类；特征解耦；多标签疾病分类；分布外泛化

目 录

一、引言	1
1.1 研究背景	
1.2 理论基础	
1.3 研究目标与本文结构	
二、相关模型理论	3
2.1 ResNet50	
2.2 Transformer 编码器	
2.3 结构因果模型 SCM	
2.4 损失函数	
三、稳定模型框架	6
3.1 模型架构	
3.2 各模块算法	
3.2.1 特征提取模块	
3.2.2 疾病分支的任务查询生成模块	
3.2.3 因果干预、分类头与损失计算模块	
3.3 超参数设置	
3.4 模型复杂度分析	
3.5 模型综述	
四、训练过程与结果	10
4.1 数据集与数据预处理	
4.2 训练环境配置	
4.3 测试结果	
4.4 实验结果分析	
五、进阶探讨	13
5.1 完整模型构想、消融与优化改进	
5.2 总结	
参考文献	15

一、引言

1.1 研究背景

疾病的诊断一直以来是人类健康的重要课题，胸部 X 光检查作为临床常用、成本相对较低的影像学手段，每年在全球范围内产生海量影像数据。传统人工阅片耗时耗力，且受医师经验与工作状态影响。随着技术发展，深度学习网络在医学图像分析领域取得了显著进展，为辅助诊断提供了重要技术基础，展现出临床应用潜力。

近年来，卷积神经网络（Convolutional Neural Network, CNN）及其变体在胸片多标签疾病分类任务上取得了显著进展。与此同时，有研究者指出^[1]：深度学习模型在学习过程中倾向于利用数据集中的统计相关性，如设备伪影、体位、曝光风格与疾病标签的共现，而不能从本质上学习病症与标签的逻辑因果特征。因而当测试分布与训练分布不一致时，分布外（Out-of-Distribution, OOD）数据将制约模型在真实临床环境中的泛化能力，性能可能明显下降^[2]，即面临领域偏移问题。

为了解决上述问题，因果表示学习（Causal Representation Learning, CRL）应运而生。Schölkopf 等人^[3]系统阐述了因果表示学习的基本框架，指出将因果推理与机器学习相结合是实现本质泛化表征的关键路径（图 1）。在医学图像分析领域，Nie 等人^[4]提出了基于因果视角的胸部 X 光分类方法，通过特征解耦和后门调整策略，使模型学习因果特征而非虚假特征，实验在 OOD 数据上展现出更好的泛化性能；Carloni 等人^[5]进一步提出了 CROCODILE 框架，通过双分支架构、特征解耦以及后门调整等策略，实现了因果特征与虚假特征的分离，在多个数据集上验证了方法的有效性；You 等人^[6]提出的 CRLTGA 模型将图注意力网络（Graph Attention Network, GAT）引入结构因果模型（Structural Causal Model, SCM），通过聚合上下文节点的因果信息来学习因果结构矩阵。




图 1 因果推断与统计推断的关系

基于上述工作，本文在 CROCODILE 与 CRLTGA 的启发下，设计面向胸片多标签疾病分类的融合框架。通过完成融合框架的实现与训练排查，本研究致力于模型能够学习到具有医学意义的因果特征，提升在分布外数据上的性能。本文重点聚焦于在真实训练条件下分析完整设计与可稳定训练版本之间的差异，给出可复现的主实验结果与稳定性消融，并系统讨论训练不稳定来源及后续改进方向。

1.2 理论基础

CRL 旨在将因果推理的思想融入深度表示学习框架，使模型能够从非结构化的原始数据中自动发现和提取具有因果结构的低维潜在表示。CRL 的总体目标是从样本中学习更利于稳定判别的表示，减弱对混杂因素的依赖。

SCM 通过概率图刻画变量之间的因果关系，引入潜在因果变量，将非结构化数据结构化处理，从而可利用运算性质对变量进行处理。SCM 用变量间的因果结构描述数据生成过程，因果推断中的干预（intervention）与后门调整（backdoor adjustment）等概念，为控制或改变混杂因素后考察结果变量提供了理论支撑。

CROCODILE 框架将因果推理融入医学图像分类，通过任务相关表示与混杂对照表示的区分，使用后门调整策略让模型在混杂因素被扰动时仍能保持对疾病标签的预测能力。该框架设计了双分支并行架构，将学习到的特征分解为因果特征和虚假特征两部分，前者用于疾病预测，后者通过均匀分布约束进行抑制；采用后门调整策略对虚假特征进行跨样本随机配对，模拟因果干预效果，阻断虚假相关路径。

本研究主要围绕因果表示学习、结构因果模型以及后门调整进行，以 CRL 为总体逻辑，以 SCM 为因果形式化工具，以后门调整为因果干预策略。我们对 CROCODILE 框架吸收并落实的核心包括：以深度网络提取胸片表征；经过 Transformer 编码器与任务查询从空间词元信息中聚合类别证据；构造混杂对照形成干预表示；以主任务头与干预头双路损失进行训练。

1.3 研究目标与本文结构

本文以《CROCODILE: Causality aids RObustness via COntrastive DIsentangled LEarning》中的模型框架为基础，期望进行以下三个方面的研究：

- （1）设计并实现训练消融稳定的 CROCODILE 因果查询分类模型；
- （2）在 CheXpert-v1.0-small 五类任务数据集上对融合模型进行评估，并与不同模型对比，分析

疾病特征之间的因果依赖关系，验证模型是否学到了具有医学意义的因果特征而非虚假相关，对模型的决策依据进行因果层面的解释；

（3）将领域双分支解耦、图结构因果学习作为扩展方向，设计融合 CROCODILE 因果干预思想和 CRLTGA 图结构学习思想的胸片分类框架，并分析该模型在小规模实验中的应用缺陷。

本文共分为五个小节，本小节为第一小节，阐述研究问题的背景与理论基础；第二小节对本文所提出的网络中核心基本概念进行解释；第三小节分模块从理论角度详细阐述本研究设计的稳定模型，给出模型的超参数设置并对复杂度进行分析；第四小节呈现实际训练过程，包括数据预处理、实验环境、实验结果与对实验结果的分析；第五小节给出最初模型构想、消融过程与当前模型的优化改进方向，最后对本次研究进行总结。

二、相关模型理论

2.1 ResNet50

ResNet50 的核心思想是给非线性的卷积层利用残差连接来提高信息的传播效率，通过让网络学习残差函数 $f(x) - x$ 来逼近 $f(x)$ 。ResNet50 的整体结构^[7]如下：

表 1 ResNet50 架构

层	块参数	输出维度
输入层		(3, 224, 224)
初始卷积层	kernel_size=7, stride=2, padding=3	(64, 56, 56)
池化层	Maxpooling	(64, 56, 56)
第 1 层	3x Bottleneck Block	(256, 56, 56)
第 2 层	4x Bottleneck Block	(512, 28, 28)
第 3 层	6x Bottleneck Block	(1024, 14, 14)
第 4 层	3x Bottleneck Block	(2048, 7, 7)
全局平均池化层	AdaptiveAvgPool	(2048, 1, 1)
全连接层		

其中，Bottleneck Block 结构如下：

1x1 卷积+BatchNormalization+ReLU

3x3 卷积+ BatchNormalization +ReLU

1x1 卷积+ BatchNormalization +ReLU

ReLU

在本研究的模型中，ResNet50 承担共享特征提取器。输入胸部 X 光图像经预处理后，通过 ResNet50 的逐层前向传播，提取的特征图作为后续模块的输入。

2.2 Transformer 编码器

Transformer 用自注意力机制替代 CNN 结构，允许序列中的每个位置直接关注序列中的所有其他位置，从而高效捕捉长距离依赖关系，计算过程具有高度并行性^[8]。

多头注意力机制的计算过程可形式化描述如下：给定输入序列 $X \in \mathbb{R}^{n \times 512}$ ，通过三个可学习的权重矩阵 $W_i^Q, W_i^K, W_i^V \in \mathbb{R}^{512 \times 64}, i = 1, \dots, 8$ 变换为查询（Query）、键（Key）和值（Value）矩阵 $Q_i = XW_i^Q, K_i = XW_i^K, V_i = XW_i^V$ 。注意力权重由查询矩阵与键矩阵的点积相似度定义：

$$\text{Attention}_i(Q_i, K_i, V_i) = \text{softmax}\left(\frac{Q_i K_i^T}{8}\right) V_i$$

将所有注意力头的输出拼接后用权重矩阵 $W^O \in \mathbb{R}^{512 \times 512}$ 映射得到多头注意力（图 2）：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{Attention}_1, \dots, \text{Attention}_8) W^O$$




图 2 多头注意力机制

在本研究的融合模型中，Transformer 编码器承担上下文特征编码的角色，对提取的特征图进行进一步编码。自注意力机制能够有效捕捉不同疾病特征之间的相关性，为后续因果结构学习提供更丰富的上下文信息。

2.3 结构因果模型 SCM

SCM 为形式化描述变量间的因果关系提供了严格的数学语言^[9]，SCM 因果图 $C \rightarrow E$ 包含以下两个基本赋值结构：

$$\begin{aligned} C &:= N_C \\ E &:= f_E(C, N_E) \end{aligned}$$

其中， N_C, N_E 分别为独立的外生噪声变量，原因变量 C 称为结果变量 E 的直接原因。

SCM 因果图 $C \rightarrow E$ 本质上是一个有向无环图，揭示了数据生成过程中的因果机制。每个变量的取值由其直接原因和外生噪声决定，而非由所有变量共同决定。

SCM 中的干预操作和反事实（Counterfactual）理论是计算因果推断概率的基础，干预操作 $X = x$ 下的 $Y = y$ 的概率为：

$$P^{C \rightarrow E; do(X=x)}(Y = y)$$

其中，干预算子 $do(\cdot)$ 用于切断所有指向 X 的因果连接，使其不再受其原有原因的影响。

反事实概率是在已有 $X = x_0$ 发生的情况下，利用因果推断干预 $X = x_1 (x_1 \neq x_0)$ 情况下 $Y = y$ 的概率：

$$P^{C \rightarrow E|X=x_0; do(X=x_1)}(Y = y)$$

由于在实际应用中，我们无法直接进行物理干预，故只能从观测数据中估计因果效应。若变量集合 Z 满足：（1） Z 中不包含 X 所指向的节点；（2） Z 阻断所有连接 X 与 Y 且指向 X 的路径；则 Z 满足后门准则（图 3），以从观测数据中估计干预的概率：

$$P^{C \rightarrow E; do(X=x)}(Y = y) = \sum_z P(Y|X = x, Z = z)P(Z = z)$$




图 3 路径 “ $X \leftarrow A \rightarrow K \rightarrow Y$ ” 是从 X 到 Y 的后门路径， K 满足后门准则

传统 SCM 要求预先指定因果图的结构和函数形式，在复杂的图像数据场景中，深度神经网络可以作为通用函数逼近器来学习未知的结构方程 $f_E(C, N_E)$ ，从而可以通过梯度下降等优化方法从数据中学习因果图结构。

2.4 损失函数

交叉熵损失函数定义如下：

对于多标签分类任务，一张图像可能同时患有多种疾病，采用二元交叉熵对每个疾病类别独立计算损失：

$$L_{BCE}(y_i, \hat{y}_i) = -\frac{1}{C} \sum_{i=1}^C (y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i))$$

其中， C 为疾病类别数， $y_c \in \{0,1\}$ 为第 c 种疾病的真实标签， $\hat{y}_c \in [0,1]$ 为模型预测概率。

三、稳定模型框架

3.1 模型架构

本文在 CROCODILE 双分支因果干预思想上，简化设计了可稳定复现的疾病主分支因果查询模型，具体架构如下图所示：




图 4 模型架构

定义下表中的变量：

表 2 变量表示及其维度

符号	维度	含义
x	$3 \times 224 \times 224$	预处理的疾病样本图像
n		批次大小
$y \in \{0,1\}$	$n \times 5$	5类标签疾病标签
F	$n \times 2048 \times 7 \times 7$	ResNet50 输出特征图
F'	$n \times 256 \times 7 \times 7$	特征学习块输出
T	$n \times 49 \times 256$	词元序列
T'	$n \times 49 \times 256$	经 Transformer 编码的词元序列
$Q, \bar{Q}$	$n \times 5 \times 256$	任务查询特征与对照表示
Z_x, Z_{bd}	$n \times 5$	疾病预测得分、疾病干预得分

模型假设胸部 X 光图像中的病灶特征、设备与体位等域相关特征可以在高维空间中部分解耦；通过对特征间的因果依赖结构显式建模，可以迫使模型依赖稳定的因果特征而非表面的虚假相关。

3.2 各模块算法

3.2.1 特征提取模块

特征提取阶段由 ResNet50 与轻量疾病特征块构成，ResNet50 采用在 ImageNet 数据集上预训练的权重初始化。特征学习块对 ResNet50 输出的特征图 F 进行二次编码，设计轻量疾病特征模块，用 1×1 卷积通道投影与 GroupNorm 映射为 F' ，替代原论文中 DModule+ACmix+Attention 的复杂路径。

3.2.2 疾病分支的任务查询生成模块

本模块完成空间上下文建模与任务级查询抽取。胸片病灶具有明确空间位置，对 F' 进行二维正弦位置编码 P 后展平为词元序列 $T = \text{flatten}(F' + P)$ ，即其中每个词元对应特征图上的一个空间位置，同时携带局部视觉语义与位置信息。将 T 输入 $L = 2, \text{nhead} = 4, d_{\text{model}} = 256$ 的 Transformer 编码器，利用自注意力机制建立多灶病变的长程依赖并输出 T' ，经 LayerNorm 后进入任务查询模块。

由于本研究无法在胸片上对设备或体位做真实干预，因此在表示层构造近似干预样本。在保持当前图像疾病表示的同时，向其中注入经打乱与随机削弱后的混杂对照，要求模型在该表示上仍能预测真实标签，以训练更稳健的疾病判别路径。

初始化可学习查询嵌入 E_q ，对批次中每张图像扩展为 $Q^{(0)}$ ，以 $Q^{(0)}$ 为查询， T' 为键、值执行多头交叉注意力，经残差、LayerNorm 与前馈网络得到 Q ，其中第 c 行可视为第 c 类疾病在整幅胸

片上的聚合证据。混杂对照 $\bar{Q}$ 查询更新中的残差部分构造：

$$\bar{Q}_c = Q_c - \text{Attention}_c$$

即利用查询更新量中未与词元信息直接对齐的部分作为批内混杂因素近似代理，供下一模块干预使用。

该模块算法如下：

算法 1. 疾病分支的任务查询生成

1. 输入：疾病特征图 F' ，疾病类别数 $C = 5$
 2. 二维正弦位置编码： $P = \text{SinePosEnc2D}(F')$;
 3. $T = \text{flatten}(F' + P)$;
 4. $T' = \text{LayerNorm}(\text{TransformerEnc}_{L=2}(T))$;
 5. **for** $c = 1:C$:
 6. $\text{Attention}_c = \text{MultiHead}(Q_c^{(0)}, T', T')$;
 7. $Q_c = \text{LayerNorm}(Q_c^{(0)} + \text{Attention}_c)$;
 8. $Q_c = \text{LayerNorm}(Q_c + \text{FFN}(Q_c))$;
 9. $\bar{Q}_c = Q_c - \text{Attention}_c$;
 10. $Q = \text{Stack}(Q_1, \dots, Q_C)$; $\bar{Q} = \text{Stack}(\bar{Q}_1, \dots, \bar{Q}_C)$;
 11. 输出：编码 T' ，任务查询 Q ，对照表示 $\bar{Q}$
-

3.2.3 因果干预、分类头与损失计算模块

主任务分类头将 3.2.2 输出的类别级任务表示 Q_c 映射为第 c 类疾病的预测输出。对每个类别 c 采用独立的线性变换将 Q 映射为五类疾病预测得分：

$$z_{x,c} = W'_c Q_c + b_c$$

干预头在表示层面构造对混杂因素施加干预后的样本，要求模型在该表示上仍能正确预测疾病。通过批内置换和 Dropout 策略模拟混杂变量改变情形，构造干预后表示 Q^{bd} ，对其映射为相应的干预分支得分：

$$z_{bd,c} = W_c^{bd'} Q_c^{bd} + b_c^{bd}$$

干预过程是训练期正则化，用于近似后门调整思想。推理阶段不使用干预路径，仅以主任务头得分作预测，对应以稳定任务表示作决策。上述设计沿袭了 CROCODILE 在表示层进行后门式干预的思路；本研究在主实验中将该机制与任务查询模块结合，并在稳定训练配置下保留主路径和干预路径的双 BCE 损失。

该模块算法如下：

算法 2. 后门干预与双头分类

1. 输入：任务查询特征 Q 与对照表示 $\bar{Q}$ ，Dropout 概率 p
2. for $c = 1:C$:
3. $z_{x,c} = W_c' Q_c + b_c$;
4. $Q^{bd} = Q + \text{Dropout}(\text{shuffle}(\bar{Q}), p)$;
5. for $c = 1:C$:
6. $z_{bd,c} = W_c^{bd'} Q_c^{bd} + b_c^{bd}$;
7. $Z_x = \text{Stack}(Z_{x,1}, \dots, Z_{x,C})$; $Z_{bd} = \text{Stack}(Z_{bd,1}, \dots, Z_{bd,C})$;
8. 输出：主任务预测得分 Z_x ，干预得分 Z_{bd}

对于每个胸片批次 X_i 及其多标签 y ，在经过前向算法 1 和算法 2 后可分别计算损失：

$$L_{main} = L_{BCE}(y, \text{sigmoid}(Z_x)) = \frac{1}{nC} \sum_{i=1}^n \sum_{c=1}^C L_{BCE}(y_c^{(i)}, \text{sigmoid}(z_{x,c}^{(i)}))$$

$$L_{bd} = L_{BCE}(y, \text{sigmoid}(Z_{bd})) = \frac{1}{nC} \sum_{i=1}^n \sum_{c=1}^C L_{BCE}(y_c^{(i)}, \text{sigmoid}(z_{bd,c}^{(i)}))$$

总误差计算公式：

$$L_{total} = L_{main} + \lambda L_{bd}$$

3.3 超参数设置

本文训练使用的超参数经过多轮数值稳定性排查后逐步收敛得到，超参数设置如下：

表 3 超参数设置

超参数	取值	说明
不确定标签	U-Ones	将 -1 视为阳性
Transformer	2 层 / 4 头	
优化器/学习率	Adam / 2e-5	学习率经过尝试后选择
Batch size	24	
梯度裁剪	1.0	防止梯度爆炸
权重衰减	1e-4	梯度更新的衰减比例
干预 Dropout 概率	0.3	控制 $\bar{Q}$ 扰动强度
训练轮数	20 epoch	
干预权重 λ	0.2	干预分支 BCE

3.4 模型复杂度分析

为更直观地说明当前稳定模型的结构开销并与原模型进行对比，本文进一步从参数规模角度对各模块进行统计。

对模型中各模块参数量估计如下：

表 4 模型参数量

网络模块	总参数 / 占比	是否参与训练
ResNet50	约 2350 万 / 7.0%	否
疾病特征块	约 15293 万 / 45.8%	否
Transformer 编码器	约 158 万 / 0.47%	是
任务查询生成器	约 53 万 / 0.16%	是
因果解耦器	约 26 万 / 0.08%	是
主任务分类头	约 0.1 万 / 约为 0	是
干预头	约 0.1 万 / 约为 0	是

本文完整模型参数量约 3.34 亿（参见 5.1 节），当前稳定模型的参数量仅占 0.71%，节约了大量的优化器状态开销。相较 CROCODILE 端到端训练全网络的做法，本文通过保留结构、轻量训练的设计，在维持因果查询与后门干预能力的前提下，显著降低了训练显存占用，体现出面向 CheXpert 五类任务的轻量化训练优势。

3.5 模型综述

综上所述，本文采用的模型吸收了 CROCODILE 在混杂因素建模与后门干预方面的思路，共享骨干特征经轻量映射与空间 Transformer 编码后，由任务查询完成按病种类别证据聚合，再经解耦模块与干预路径完成训练期正则，推理仅依赖主任务头。

本文贡献在于形成一条结构清晰的可复现主实验，创新点可概括为：

- （1）胸片多标签场景下的任务查询与干预式训练一体化；
- （2）疾病表示与干预表示显式对照，在表示层落实混杂扰动来近似后门调整；
- （3）在公开划分下以更轻量化的模型完成主实验，结果可复核。关于本模型的最初完整架构留作后续讨论，参见 5.1 节。

四、训练过程与结果

4.1 数据集与数据预处理

本文主实验使用 CheXpert-v1.0-small 数据集^[10]，并采用五类公开协议进行训练与验证，数据均来自 Stanford 发布的胸部 X 光图像集合。

实验中保留的五类疾病标签分别为 Atelectasis、Cardiomegaly、Consolidation、Edema 和 Pleural Effusion。本文还引入两个分布外数据集：摄影分布偏移 CheXphoto 与外部医院来源数据 Indiana University Chest X-ray Collection，用于测试模型在分布外的排序能力与鲁棒性。

本实验采用的数据预处理包括：

- (1) 采用 U-Ones 处理不确定标签，即将数值为-1 的情况视为阳性标签；
- (2) 所有胸片均被统一缩放到固定输入尺寸，采用 ImageNet 预训练模型一致的标准化方式；
- (3) 训练阶段加入了适度的数据增强，以模拟旋转、翻转和亮度变化等常见扰动；验证阶段不使用随机增强，以保证不同实验结果之间具有可比性。

4.2 训练环境配置

模型训练与评估均在单张 NVIDIA RTX 4060 Ti 显卡上完成，框架采用 PyTorch。基准单模型完成 20 个 epoch 共耗时约 2.4 小时，单个 epoch 的训练与验证开销总体在 7 分钟左右。由于本研究后期发现复杂路径存在明显非有限梯度风险，因此所有主要结论均基于能够完整运行并稳定保存验证指标的实验。

4.3 测试结果

主实验在 CheXpert 五类验证集上比较了传统的 ResNet50、Xi et al.文章^[11]中提出的模型、本文原模型结构 CROCODILE 以及当前最佳 weighted checkpoint soup 稳定模型（表 5）。

表 5 不同模型在训练数据集上的测试结果

数据集	类型	AUC			
		ResNet50	Xi et al.	CROCODILE	Ours
CheXpert valid	Atelectasis	0.65	0.77	0.77	0.787256
	Cardiomegaly	0.81	0.87	0.82	0.758062
	Consolidation	0.69	0.74	0.81	0.898990
	Edema	0.77	0.84	0.88	0.877837
	Pleural Effusion	0.77	0.83	0.89	0.860577
	mean	0.738	0.810	0.832	0.837

考虑到 Indiana 数据的报告标签与 CheXpert 五类并不完全一致，本文在该数据集上保守评估 Atelectasis、Cardiomegaly 与 Pleural Effusion 三类（表 6）。

表 6 稳定模型在 OOD 数据集上的测试结果

数据集	mean AUC	F1
CheXphoto	0.792	0.57589
Indiana	0.722	0.35233
CheXpert	0.837	0.64284

可以看出，模型在分布外场景下仍存在一定泛化压力，当前方法的优势主要体现在验证集上的稳定排序能力。

4.4 实验结果分析

实验训练曲线如下：




图 5.1 损失曲线 图 5.2 验证集 macro 正确率与 tuned macro F1 曲线

图 5.3 macro F1（阈值 0.5）曲线 图 5.4 平均准确率（阈值 0.5）曲线

图 5.1 表明训练总损失与验证总损失均随 epoch 逐步下降，在当前损失设定下优化过程总体稳定，模型能够持续收敛。图 5.2 显示验证集 macro AUC 由 0.799 上升至 0.837，tuned macro F1 由 0.585 升至 0.646，模型在不依赖固定阈值的排序能力与按类调阈值后的分类表现上均获得持续改善。图 5.3 展示了 macro F1@0.5 曲线，其中验证集波动较为明显，个别 epoch 会出现阶段性回落，说明在 CheXpert 五类任务的类别不平衡条件下，统一采用 0.5 阈值难以兼顾各病最优决策点，固定阈值下的 F1 更多反映阈值与概率校准问题，不宜单独作为模型排序能力的判据。图 5.4 为平均准确率曲线，可认为模型已学到有效的相对排序信息，验证了模型学到的判别信息主要编码于概率的相对排序结构中，而非依赖某一特定阈值下的判决。

AUC 作为不依赖于分类阈值的排序性指标，其持续抬升直接反映了模型对五类胸片病变相对风险排序能力的增强，意味着模型能够将阳性病例的预测概率置于阴性病例之上，即使在类别高度不平衡的多标签场景下依然稳健。模型的排序能力优势在临床筛查场景中具有直接价值，医生无需预先设定最优阈值，即可在任意数据集上依据模型输出的风险排序优先审阅高概率病例。

五、进阶探讨

5.1 完整模型构想、消融与优化改进

前文已经提及，CRLTGA 模型关注如何从非结构化数据中显式学习因果结构。其核心创新是通过 GAT 的自适应注意力机制动态构建因果结构矩阵 A_G 。在变分自编码器框架中引入三元组损失，通过最小化相似样本在潜在空间中的距离、最大化非相似样本的距离，增强因果表示的判别性。

基于此想法，本研究最初的设计目标是将 CROCODILE 的因果特征解耦思想与 CRLTGA 的图注意力因果结构学习机制融合，构建一个面向胸部 X 光多标签分类的因果表示学习模型。完整结构框架图如下：




图 6 完整模型（虚线为稳定模型中退化的部分）

此融合框架在理论上具有较强的因果解耦与泛化潜力，然而在实际训练中，当双分支、DAG 及 CROCODILE 式重型特征块同时启用时，该完整结构表现出严重的数值不稳定问题。

为定位不稳定来源，我们在训练器中加入了前向输出、损失函数与梯度的三层次数值检查。关键发现是失败类型为非有限梯度，最早失败发生在约第 5 个批次，筛查表明复杂损失组合对骨干网络产生了过大的梯度压力。基于这一发现，我们展开了一系列逐层消融实验。逐步增加冻结深度后发现，冻结到 layer2 时崩溃推迟但仍在深层参数上失败，冻结到 layer3 时可完成单 epoch 但全量训练后期崩溃，而冻结到 layer4 后训练趋于稳定。在 RTX 4060 Ti 8GB、小批次、混合精度训练与多分支损失的组合下，完整骨干网络微调是首要不稳定源，因此后续实验采用 `freeze_backbone_until = layer4`，将骨干网络作为冻结特征提取器。随后崩溃点转移到疾病特征学习块的参数上，说明 CROCODILE 的复杂特征模块（DModule、ACmix、Attention）也是不稳定源。为此，我们在 CROCODILE 特征学习块中增加了旁路选项，跳过复杂路径，仅保留轻量的投影与标准化。

考虑到 CheXpert 数据集的领域标签仅为 Frontal/Lateral，其对疾病分类的增益不明确，我们将领域分支完全冻结并将领域分支的损失权重设为零。经过上述消融与改进，我们获得了第一个可稳定训练 10 个 epoch 的模型版本。该稳定化模型虽然解决了训练崩溃问题，但其默认阈值 0.5 下的平均 F1 值仅为 0.31–0.34，而 Consolidation 上 AUC 高达 0.87，说明模型已具备良好的排序能力，但默认阈值将所有预测压为阴性；经每类阈值校准后，平均 F1 值可提升至约 0.64。为在稳定基础上进一步提升性能，我们尝试了 weighted checkpoint soup，即将两个训练轨迹不同的 checkpoint 按比例进行参数平均。我们将稳定单模型（平均 AUC 为 0.83637）与一个经 30 epoch 余弦调度训练得到的模型（平均 AUC 为 0.83570）以 0.91 比 0.09 的比例加权平均，得到的新 checkpoint 将平均 AUC 提升至 0.83648，成为当前全局最佳结果。

综上，本研究的消融实验表明：完整因果融合框架在理论上具有优势，但在实际训练中需要大量稳定化工程；评估指标的选择显著影响结论，AUC 与调整的 F1 值比默认阈值下的 F1 值更能反映模型真实能力。未来工作将聚焦于稳定性改进、类别不平衡问题的系统处理，以及在稳定前提下逐步恢复冻结的框架，进一步探索提升分类性能。

5.2 总结

本文基于 CROCODILE 因果干预思想，针对胸部 X 光多标签疾病分类中的分布外泛化问题，详细分析了一种可稳定训练的因果查询模型及其完整融合框架的消融过程。研究从医学影像分析中的虚假相关与领域偏移问题出发，将疾病分类任务抽象为带混杂因素的因果表示学习问题，明确了完整框架在真实训练条件下的数值稳定性挑战。

从模型架构角度，本文将稳定模型划分为三个阶段：第一阶段采用冻结的 ResNet50 与轻量

特征投影提取共享视觉特征；第二阶段通过空间 Transformer 编码器与任务查询生成模块，将特征图编码为词元序列并聚合类别级疾病证据；第三阶段通过批内置换与 Dropout 构造干预表示，以双路 BCE 损失实现后门调整的近似训练。完整融合框架在此基础上进一步引入领域分支、图注意力因果结构矩阵、三元组损失与 DAG 无环约束，但因数值不稳定问题在本文主实验中作为消融分析的对象。

本文模型适用于医学影像分析中需要兼顾分类性能与因果可解释性的场景。从实际应用价值来看，本研究提出的更轻量的因果查询与干预训练框架可以推广到其他存在混杂因素与分布偏移的医学影像分析任务，如眼底疾病筛查、皮肤病变分类等；另一方面，关于复杂因果融合框架在真实数据与硬件约束下的稳定性消融分析，为因果表示学习在医学领域的工程化落地提供了可复现的参考案例。

参考文献

- [1] Castro, D. C., Walker, I., & Glocker, B. (2020). Causality matters in medical imaging. *Nature Communications*, 11(1), 3673.
- [2] Pooch, E. H., Ballester, P., & Barros, R. C. (2020, October). Can we trust deep learning based diagnosis? the impact of domain shift in chest radiograph classification. In *International workshop on thoracic image analysis* (pp. 74-83). Cham: Springer International Publishing.
- [3] Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612-634.
- [4] Nie, W., Zhang, C., Song, D., Bai, Y., Xie, K., & Liu, A. A. (2023, October). Chest X-ray image classification: a causal perspective. In *International Conference on Medical Image Computing and Computer-Assisted Intervention* (pp. 25-35). Cham: Springer Nature Switzerland.
- [5] Carloni, G., Tsafaris, S. A., & Colantonio, S. (2024, October). Crocodile: Causality aids robustness via contrastive disentangled learning. In *International Workshop on Uncertainty for Safe Utilization of Machine Learning in Medical Imaging* (pp. 105-116). Cham: Springer Nature Switzerland.
- [6] You, D., Li, Z., Shen, J., Yu, Z., Jin, S., & Wu, X. (2026). Disentangled representation learning with causal effect transmission in variational autoencoder. *Pattern Recognition*, 170, 112018.
- [7] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [8] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- [9] Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of causal inference: Foundations and learning algorithms*. MIT Press. <https://mitpress.mit.edu/books/elements-causal-inference>
- [10] Irvin, J., Rajpurkar, P., Ko, M., Yu, Y., Ciurea-Illcus, S., Chute, C., ... & Ng, A. Y. (2019, July). Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 33, No. 01, pp. 590-597).
- [11] Ouyang, X., Karanam, S., Wu, Z., Chen, T., Huo, J., Zhou, X. S., ... & Cheng, J. Z. (2020). Learning hierarchical attention for weakly-supervised chest X-ray abnormality localization and diagnosis. *IEEE transactions on medical imaging*, 40(10), 2698-2710.

附：代码文件

https://github.com/zhangjie20231127/mech_term_paper/tree/main